RNN

강 의

임 경 태

CONTENTS

목적 : RNN의 구조와 RNN개념 이해

목표 : RNN에 구조와 사용하는 이유 이해

내용 : RNN 구조, 동작 원리

CONTENTS

시계열 데이터??

- 시계열(時系列, 영어: time series)은 일정 시간 간격으로 배치된 데이터들의 수열을 말한다. (위키)
  - 시계열(time series) 데이터는 관측치가 시간적 순서를 가진 데이터이다.
  - 과거의 데이터를 통해서 현재의 움직임 그리고 미래를 예측하는데 사용된다

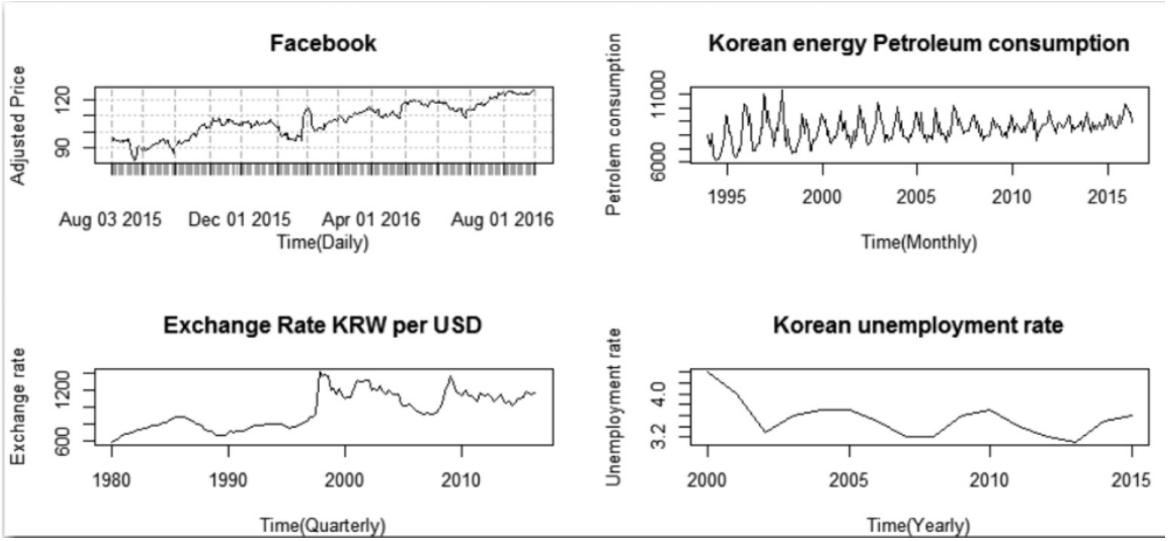

이미지 https://velog.io/@sdubee10/ZeroBase-%EC%8B%9C%EA%B3%84%EC%97%B4%EB%8D%B0%EC%9D%B4%ED%84%B0-Time-Series-Data

시계열 데이터??

- NCSoft의 2년 주가 흐름을 기반으로 내일 주가를 예측하려고 한다. 어떻게 하면 될까?
  - (1) 2년치 데이터 전부를 입력으로 FCN에 넣으면 될까? --> 너무 많음..
  - (2) 그러면 월~금 5일 데이터를 FCN에 넣자 --> 월->화->수 연속된 시간 순서관계 모델링 못함
  - (3) 시간에 따라 이전 가격을 고려해서 모델링 하는 방법은 없을까?

A	B	C
date	num_search	stock_price
2021.3.21	38	932000
2021.3.28	39	834000
2021.4.4	36	885000
2021.4.11	31	906000
2021.4.18	32	894000
2021.4.25	27	861000
2021.5.2	27	820000
2021.5.9	26	850000
2021.5.16	29	823000
2021.5.23	26	856000
2021.5.30	29	854000
2021.6.6	30	858000
2021.6.13	31	848000
2021.6.20	37	825000
2021.6.27	34	820000
2021.7.4	40	834000
2021.7.11	29	778000
2021.7.18	27	809000
2021.7.25	25	809000
2021.8.1	24	812000
2021.8.8	31	790000
2021.8.15	35	853000
2021.8.22	38	709000

What is RNN(Recurrent Neural Network)?

- 연속적이며 순서가 있는 데이터(시계열 데이터, 자연어, 음성 등)에 적합한 딥러닝 모델

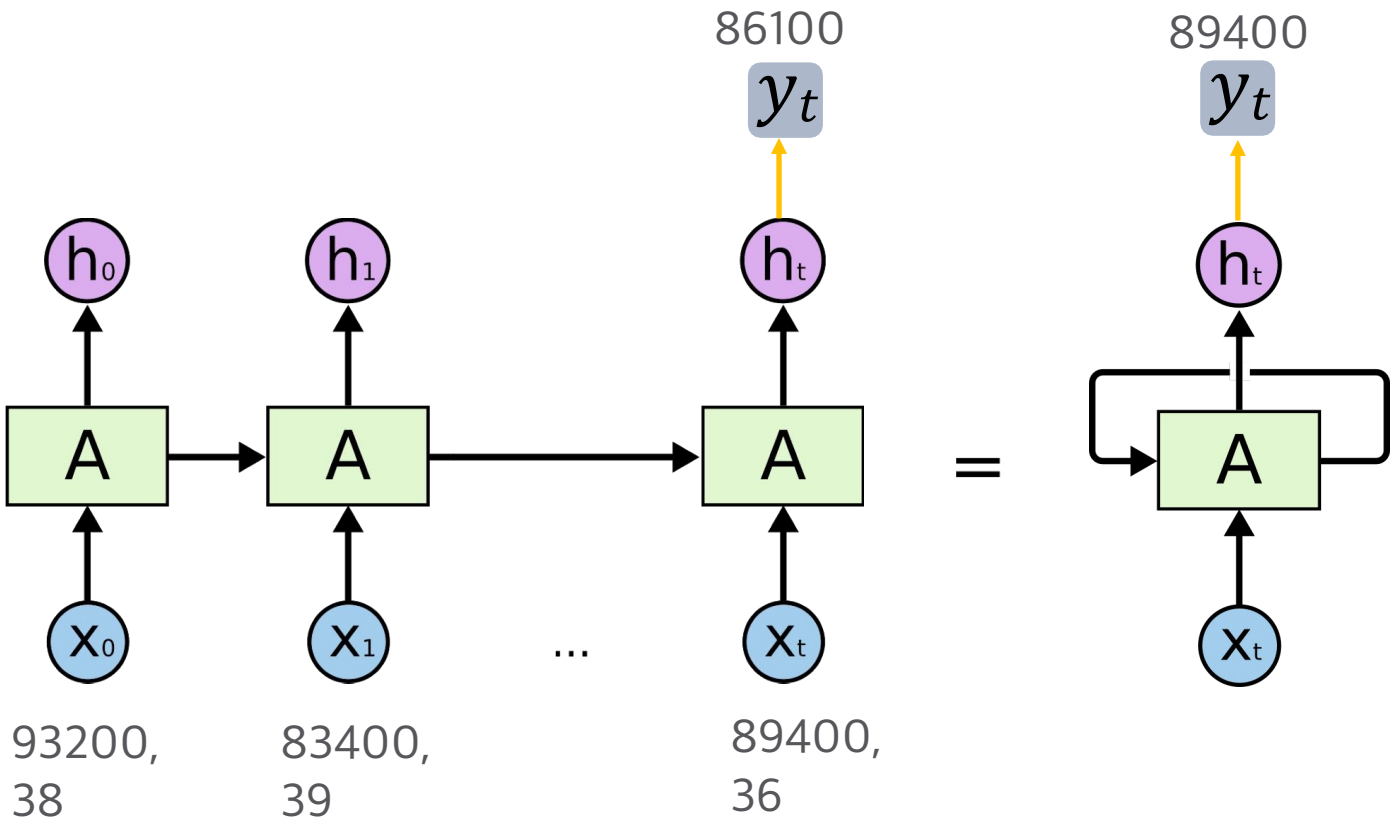

A	B	C
date	num_search	stock_price
2021.3.21	38	932000
2021.3.28	39	834000
2021.4.4	36	885000
2021.4.11	31	906000
2021.4.18	32	894000
2021.4.25	27	861000
2021.5.2	27	820000
2021.5.9	26	850000
2021.5.16	29	823000
2021.5.23	26	856000
2021.5.30	29	854000
2021.6.6	30	858000
2021.6.13	31	848000
2021.6.20	37	825000
2021.6.27	34	820000
2021.7.4	40	834000
2021.7.11	29	778000
2021.7.18	27	809000
2021.7.25	25	809000
2021.8.1	24	812000
2021.8.8	31	790000
2021.8.15	35	853000
2021.8.22	38	709000

RNN 개요

intuition of RNN

(input + empty_hidden) -> hidden -> output
(input + prev_hidden) -> hidden -> output
(input + prev_hidden) -> hidden -> output
(input + prev_hidden) -> hidden -> output

사용하는 것을 색으로 표시

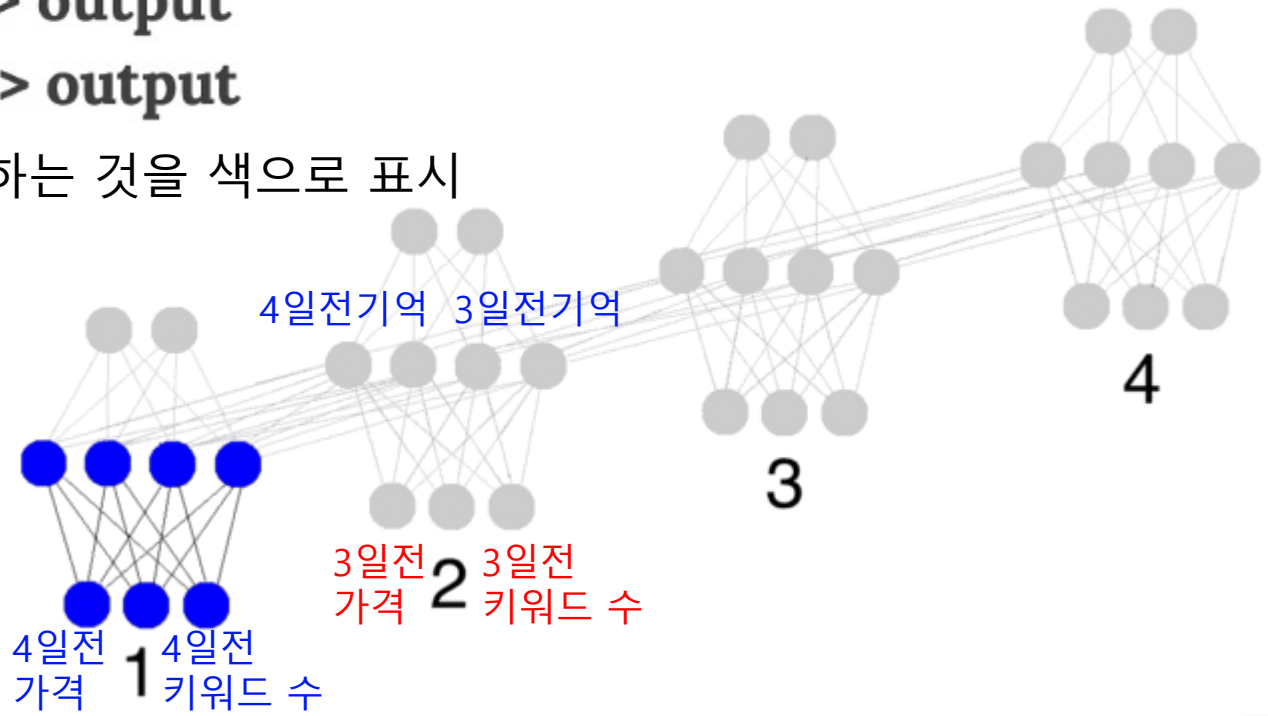

그림 출처 : https://medium.com/@serbanliviu/the-intuition-behind-recurrent-neural-networks-6fce753fe9f0

CONTENTS

FCN vs RNN의 구조 비교

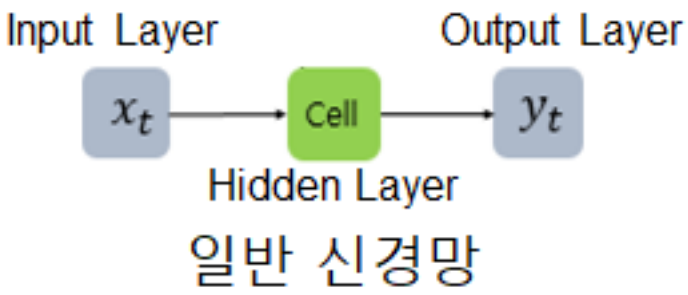

Core idea:
Apply the same weights W repeatedly!

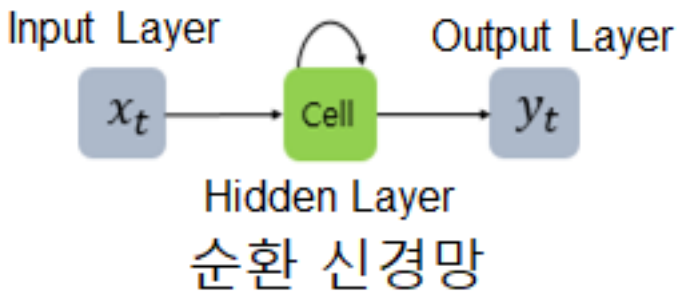

그림 출처 : https://wikidocs.net/book/2155

RNN 구조

RNN 표현

아래의 RNN은 기본적으로 입, 출력이 벡터로 가정되고 있다.

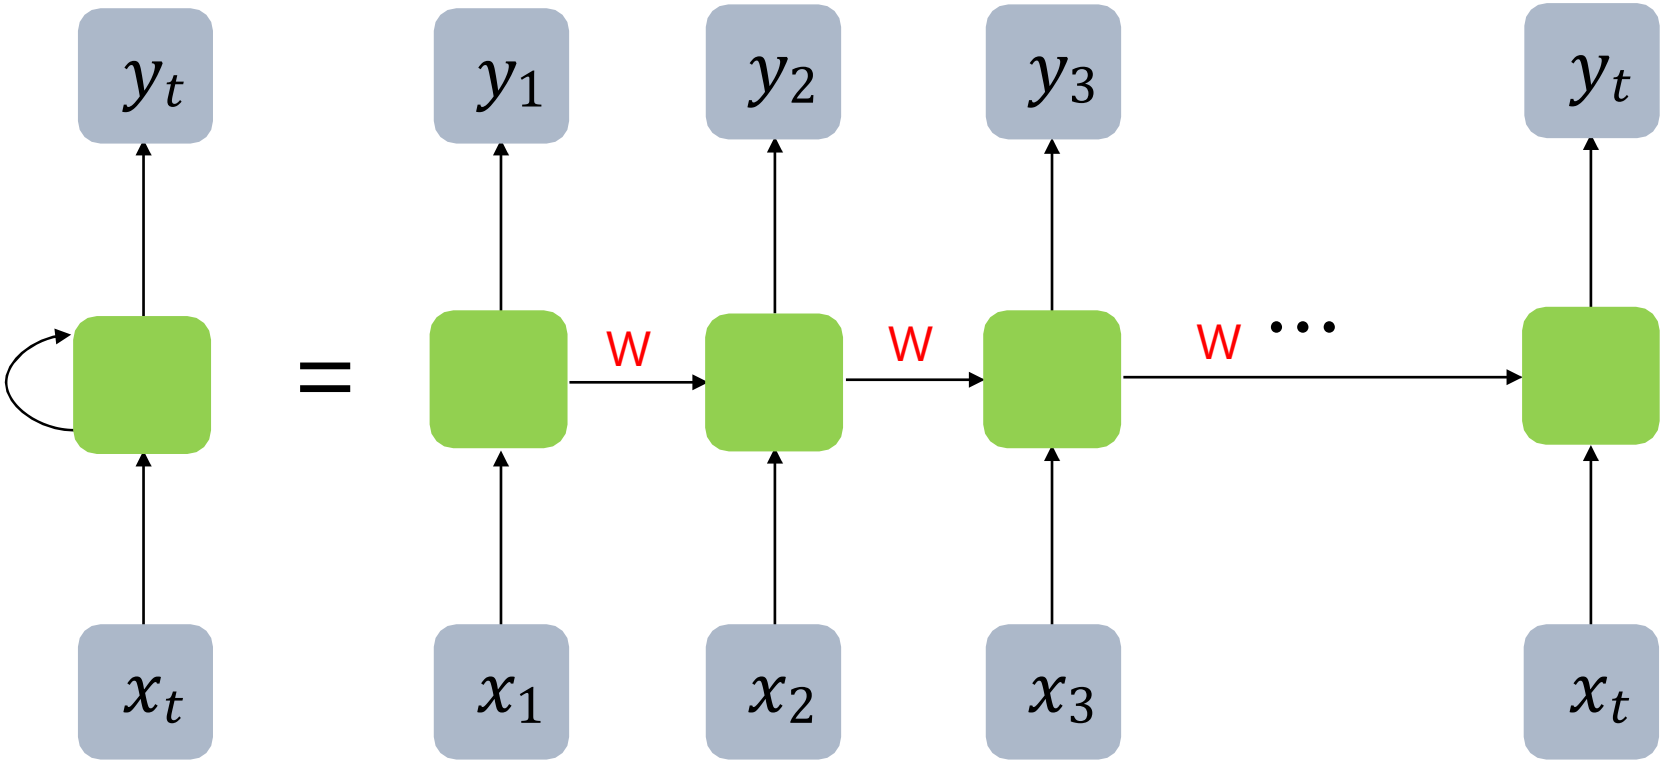

Core idea:
Apply the same weights W repeatedly!

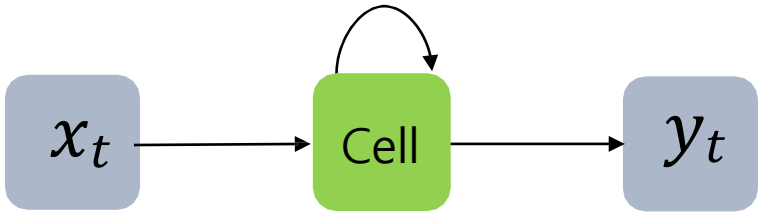

그림 출처 : https://wikidocs.net/book/2155

RNN 표현

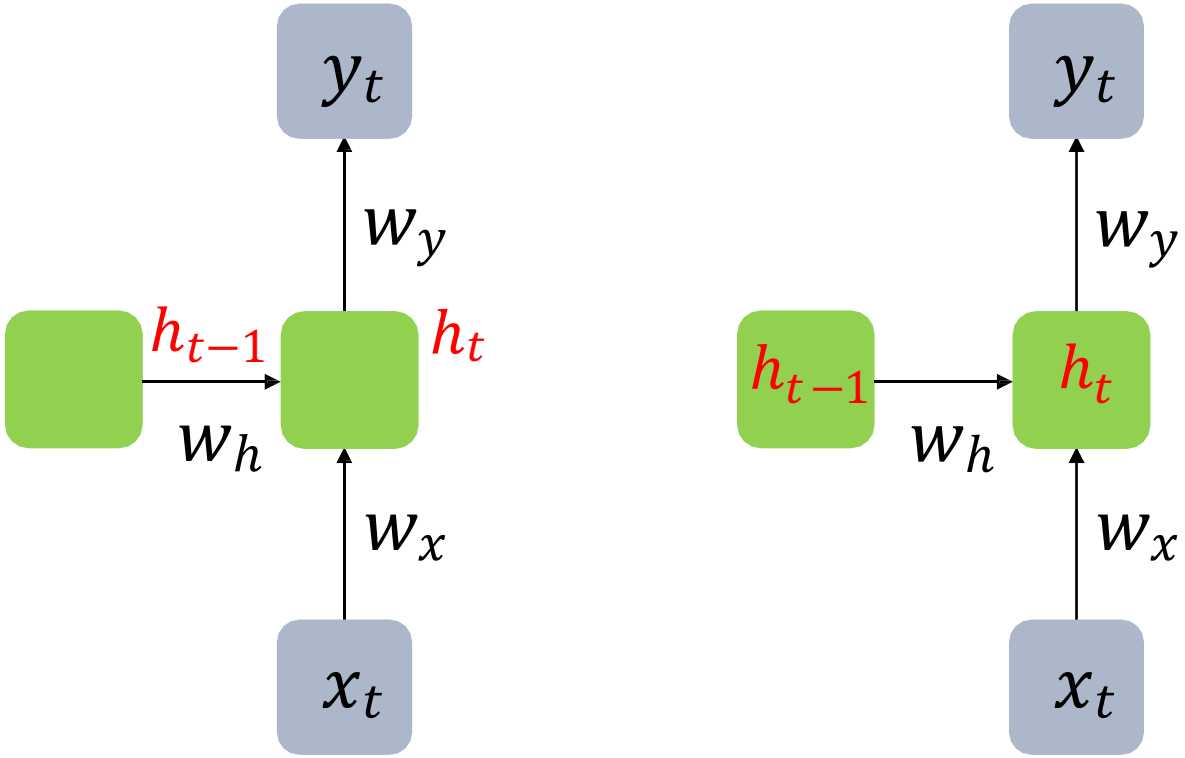

Core idea:
Apply the same weights W repeatedly!

그림 출처 : https://wikidocs.net/book/2155

RNN 상세 표현

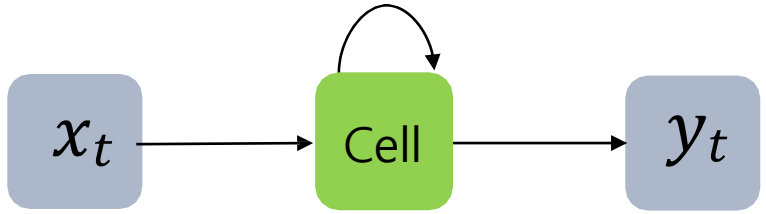

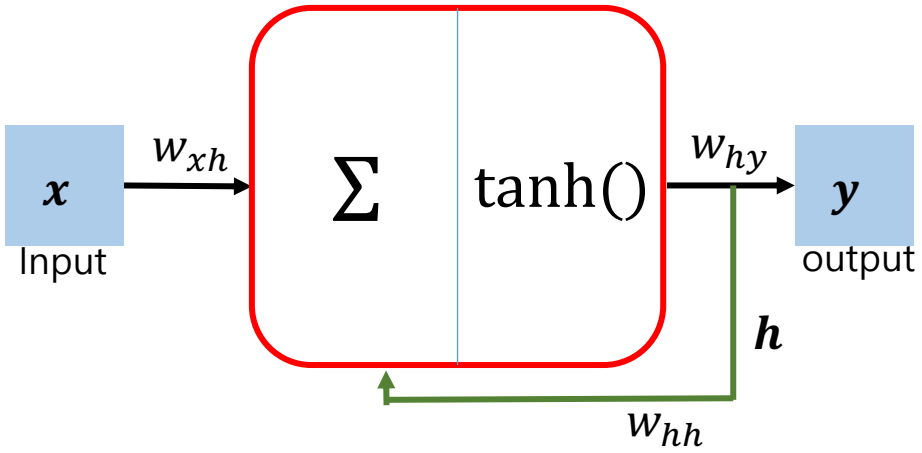

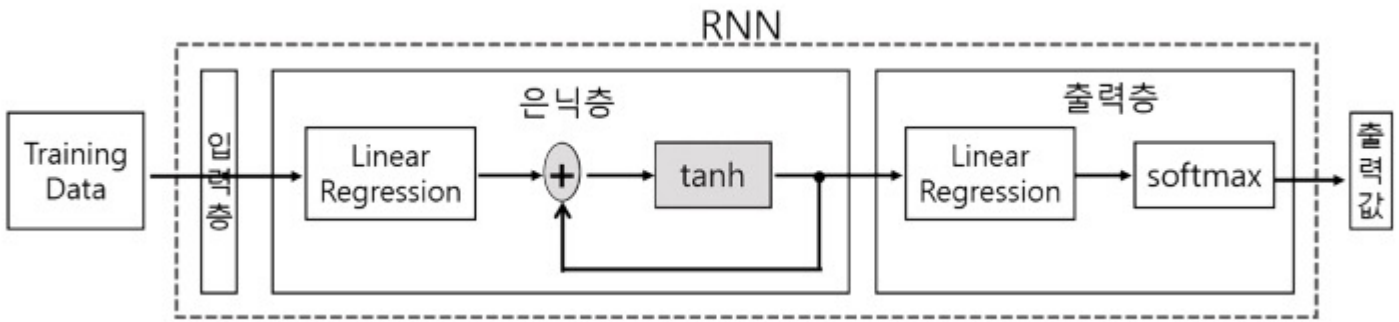

그림 출처 : 머신러닝을 위한 파이썬 한조각

RNN 상세 표현

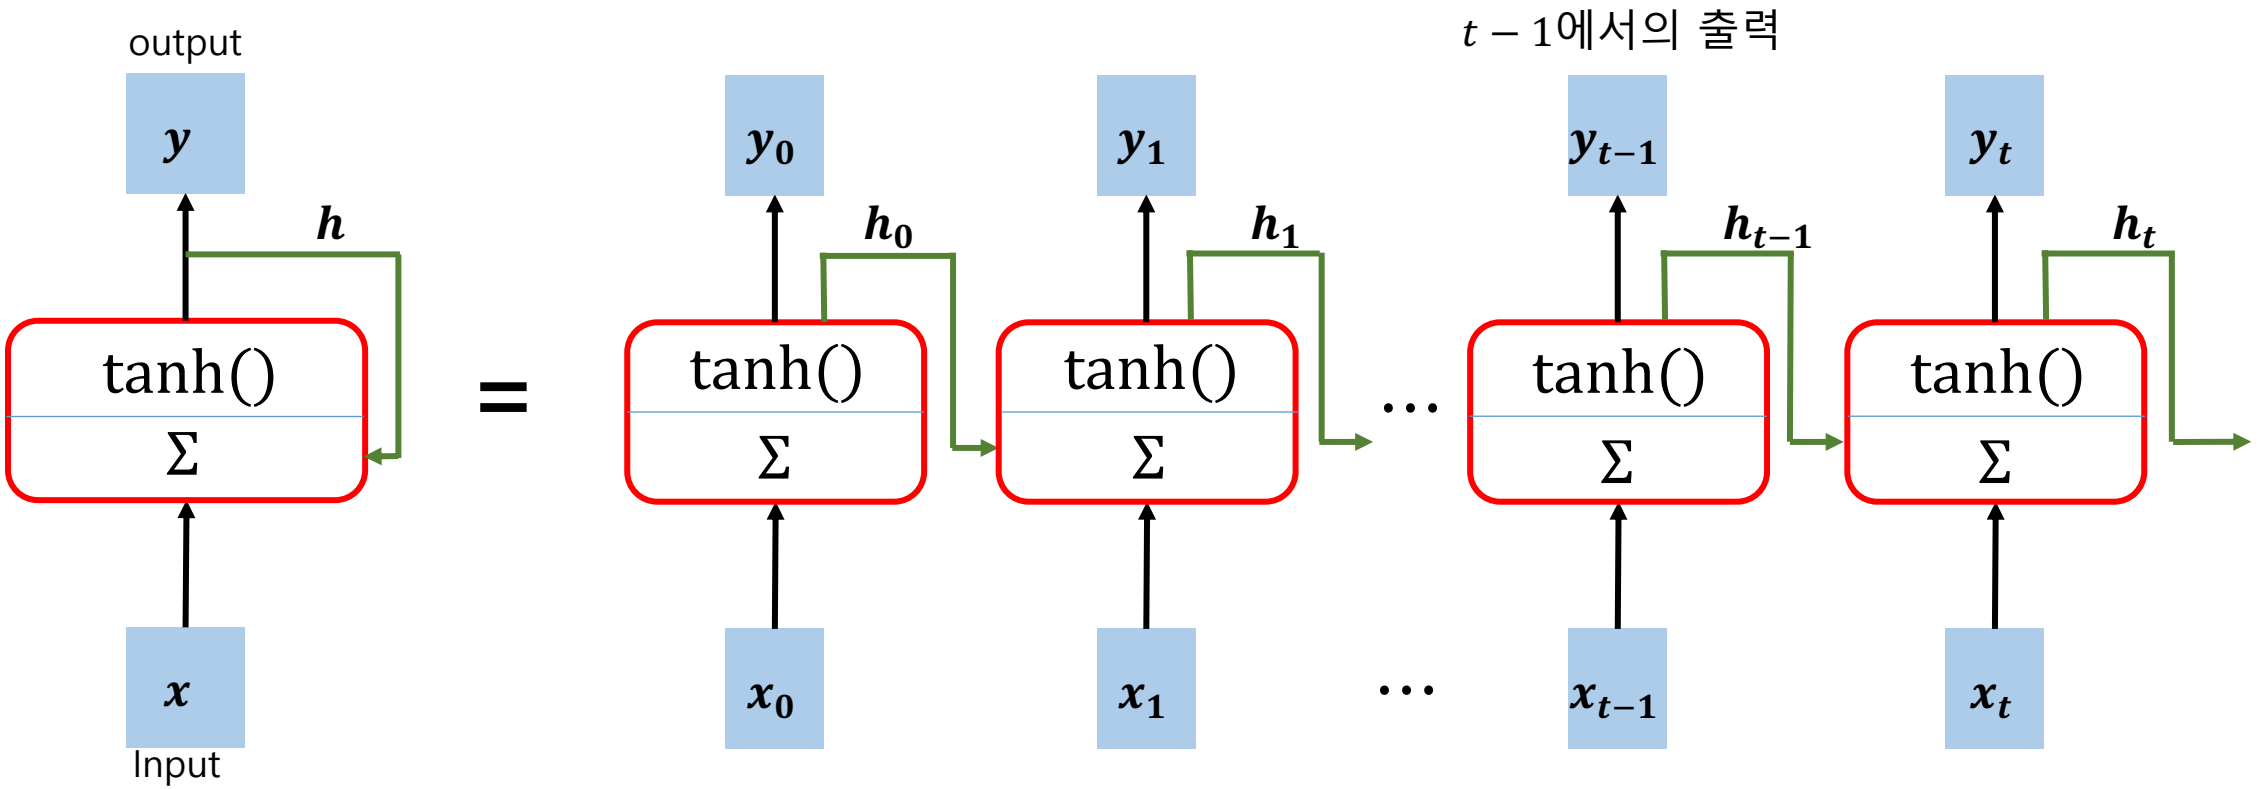

x_t : 모든 샘플의 입력값 (input)
y_t : 타임 스텝 t에서 각 샘플에 대한 순환 층의 출력값
h_t : hidden state, $h_t = f(h_{t-1}, x_t)$ 즉, 이전 hidden state와 입력값에 의해 현재 hidden state 결정

Hidden state : 다음 시점으로 넘겨줄 정보

RNN 상세 표현

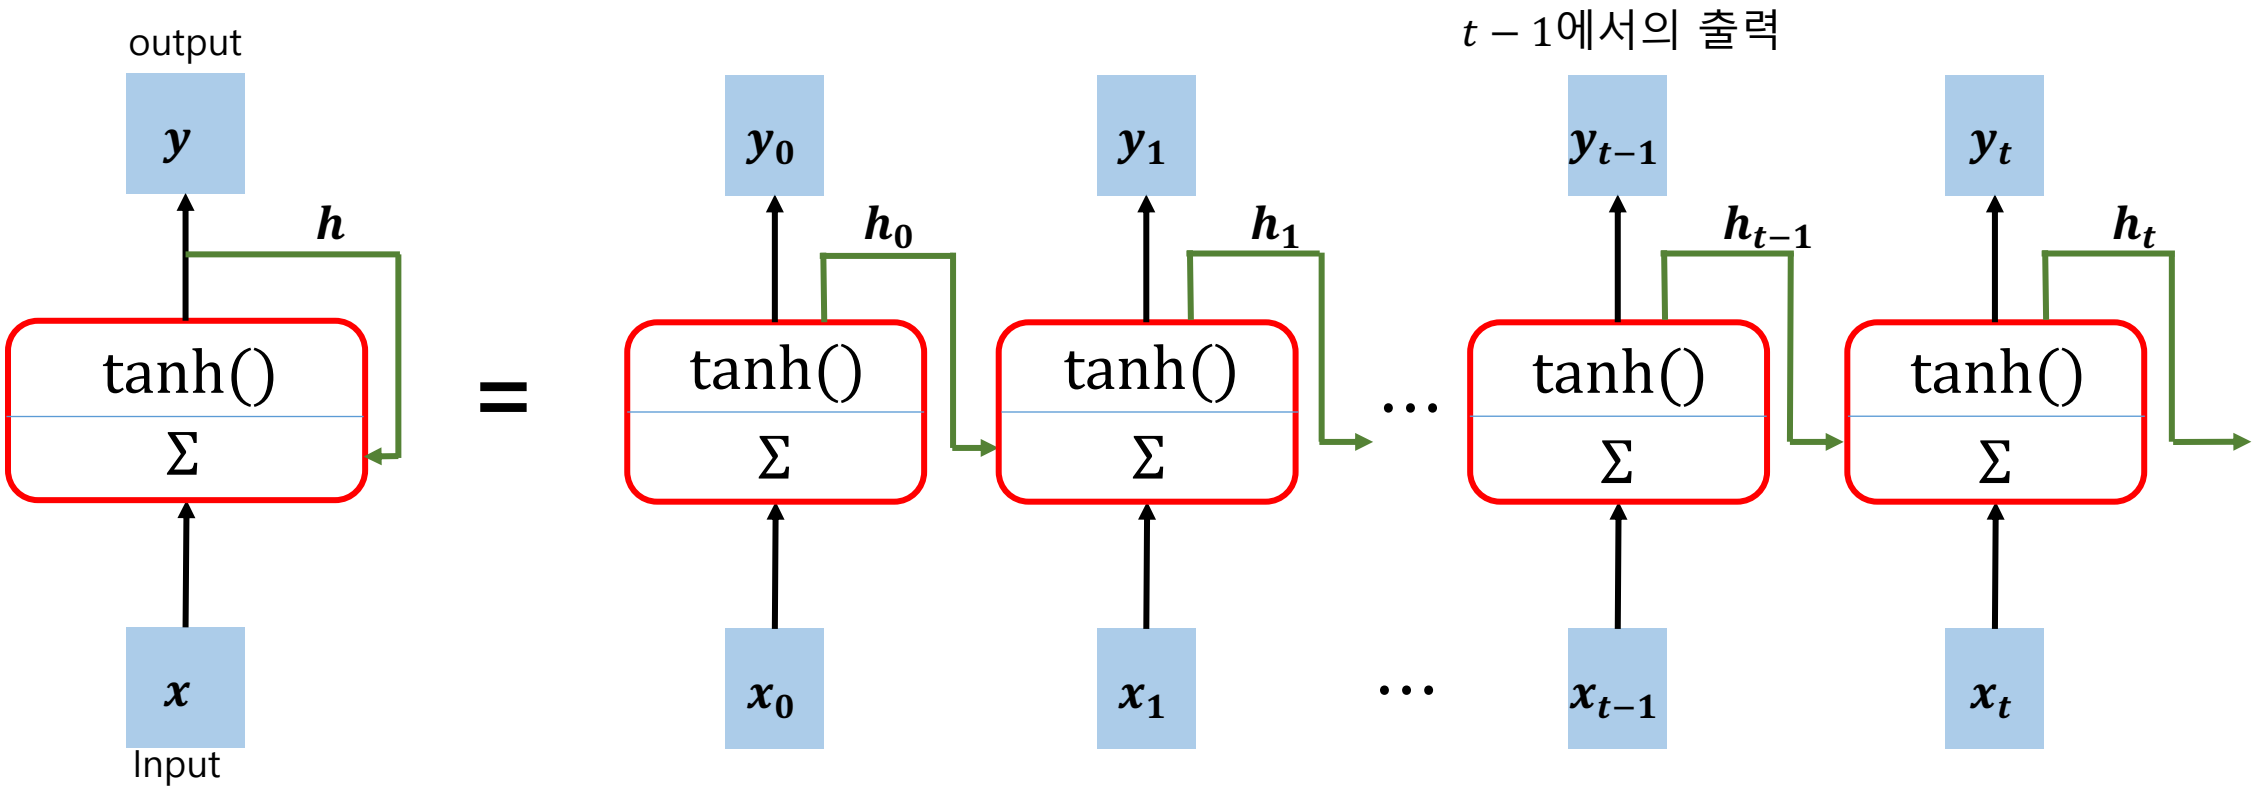

$$h_t = \tanh(X_t \cdot W_{xh} + h_{t-1} \cdot W_{hh} + b)$$
$$y_t = W_{hy} \cdot h_t$$

RNN 상세 표현 (Stanford 224n)

output distribution

$$\hat{\boldsymbol{y}}^{(t)} = \text{softmax}\left(\boldsymbol{U}\boldsymbol{h}^{(t)} + \boldsymbol{b}_2\right) \in \mathbb{R}^{|V|}$$

hidden states

$$\boldsymbol{h}^{(t)} = \sigma\left(\boldsymbol{W}_h\boldsymbol{h}^{(t-1)} + \boldsymbol{W}_e\boldsymbol{e}^{(t)} + \boldsymbol{b}_1\right)$$

$\boldsymbol{h}^{(0)}$ is the initial hidden state

word embeddings

$$\boldsymbol{e}^{(t)} = \boldsymbol{E}\boldsymbol{x}^{(t)}$$

words / one-hot vectors

$$\boldsymbol{x}^{(t)} \in \mathbb{R}^{|V|}$$

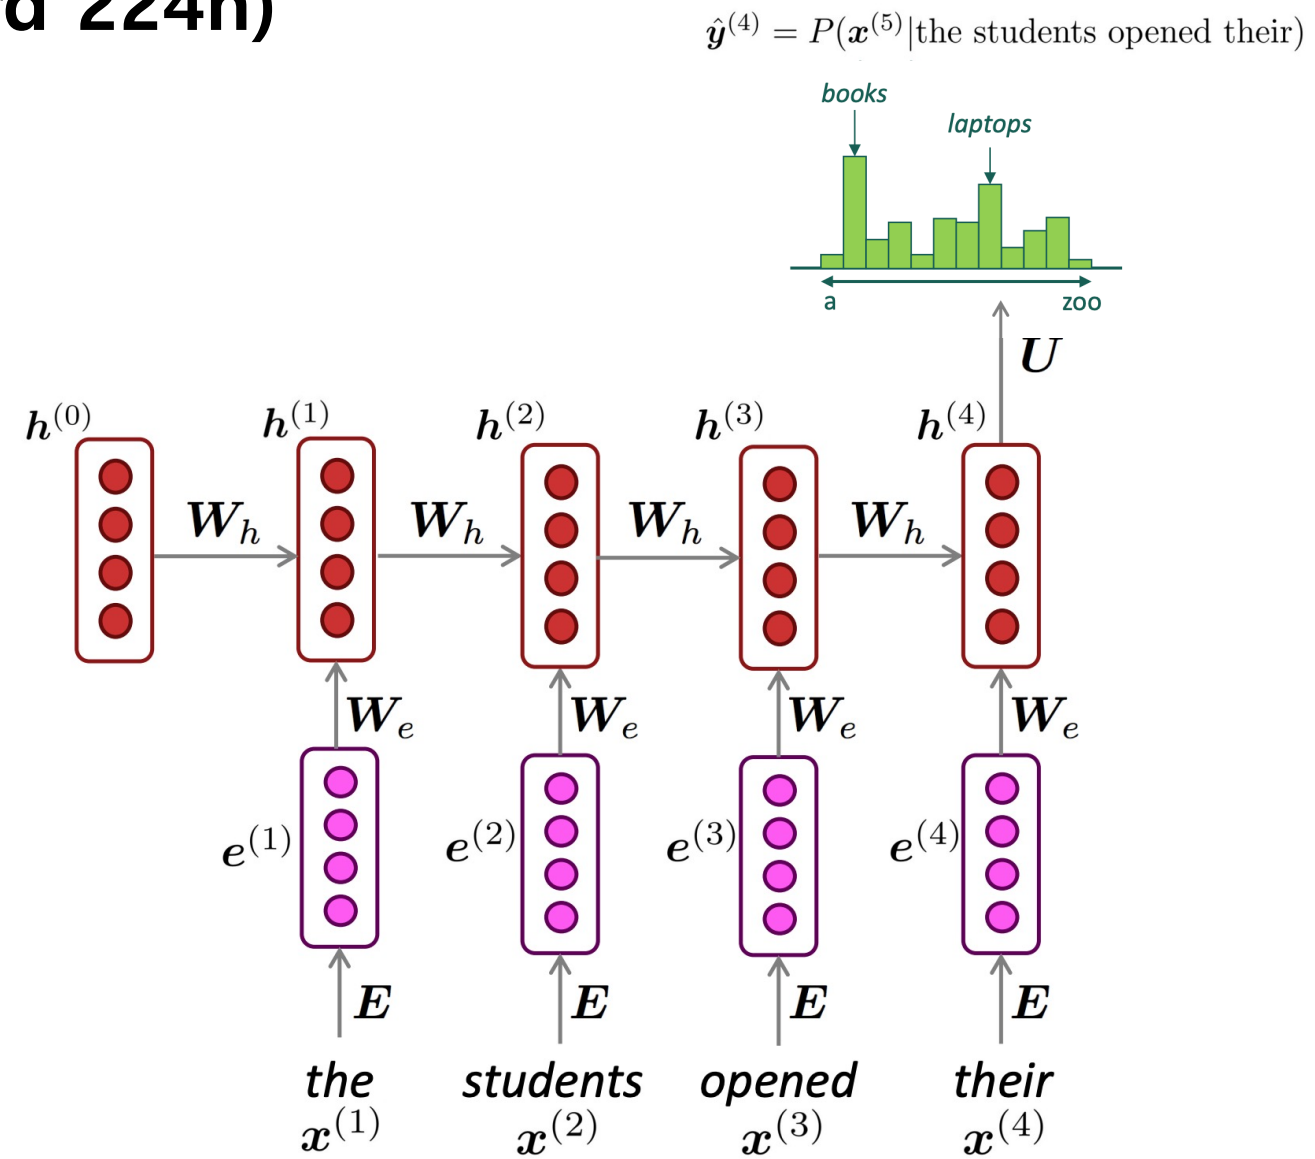

Why Hyperbolic Tangent?

- Sigmoid 함수는 음수의 경우 0에 가깝게 표현되며, 이를 미분하면 최대값이 0.25으로 Vanishing Gradient발생
  - Backpropagation 할때 sigmoid의 미분값을 곱하는 과정이 포함됨 따라서, 은닉층의 깊이가 깊어 sigmoid를 많이 사용할 경우 곱해지는 미분값이 0에 가까워 지기 때문에 weight parameter (w) 값들을 업데이트 할 때 매우 작은 범위로 업데이트됨

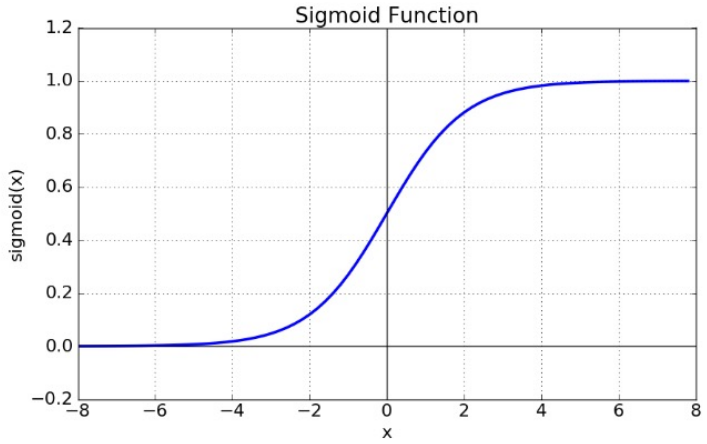

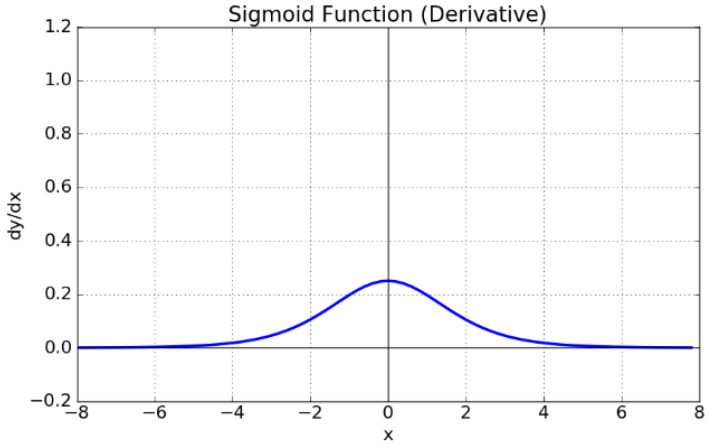

$$\frac{d}{d_x} sigmoid(x) = sigmoid(x)(1 - sigmoid(x))$$

Why Hyperbolic Tangent?

- RNN에서 Vanishing Gradient를 그나마 줄여주기 위해 Tanh Function 사용
  - Tanh 함수의 경우 미분값이 최대 1임. (여전히 1이하의 값이 계산되기 때문에 Vanishing gradient는 발생함)

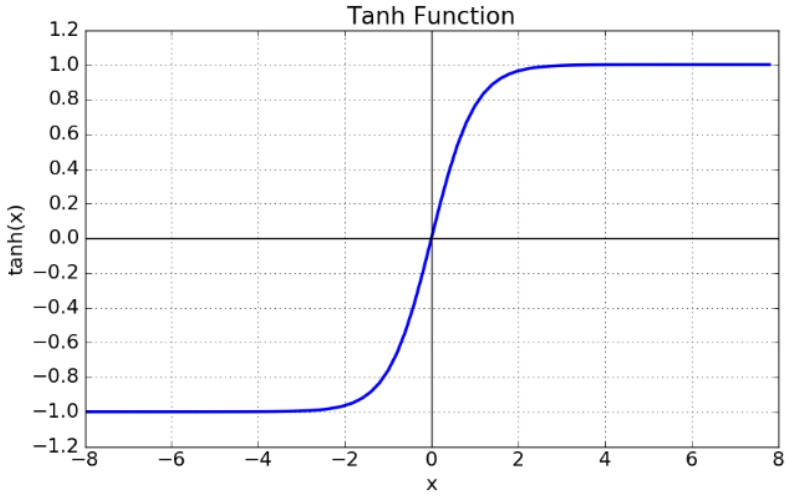

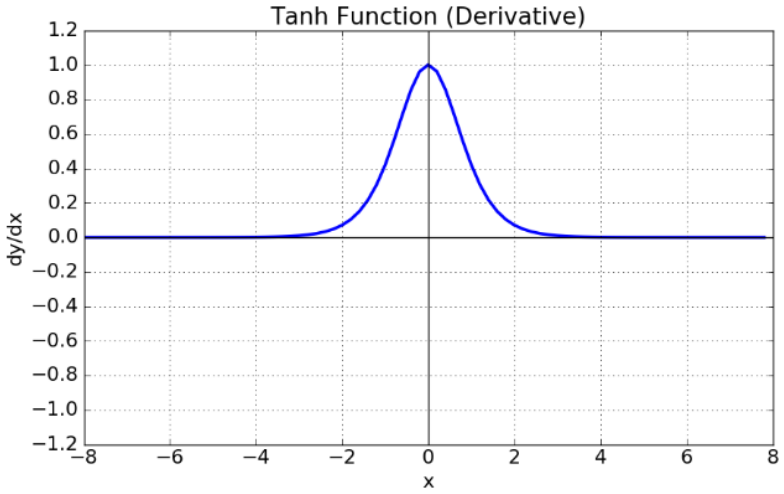

$$h_t = \tanh(X_t \cdot W_{xh} + h_{t-1} \cdot W_{hh} + b)$$
$$y_t = W_{hy} \cdot h_t$$

$$tanh(x) = 2\sigma(2x) - 1$$

$$tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

$$tanh'(x) = 1 - tanh^2(x)$$

Why Hyperbolic Tangent?

- RNN에서는 Relu를 왜 안쓰죠?
  - RNN의 내부가 계속 순환하는 구조 이므로 relu를 통과한 f(x)의값이 1보다 크게 값이 발산할 수 있기 때문에 적합하지 않음.
  - 결론적으로 tanh는 기울기가 0~1 이기 때문에 normalization 기능이 포함되어 값의 발산을 막을 수 있다고 판단할 수 있음.

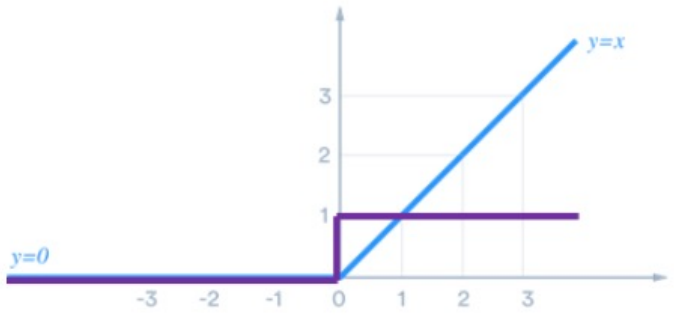

$ReLU$	
$f(x)$	$\max(0,x)$
$\frac{d}{dx}f(x)$	$\begin{cases}1 & (x \geq 0) \\ 0 & (x < 0)\end{cases}$

RNN 구조

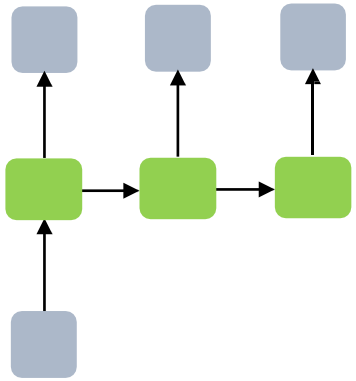

일 대 다(one-to-many)

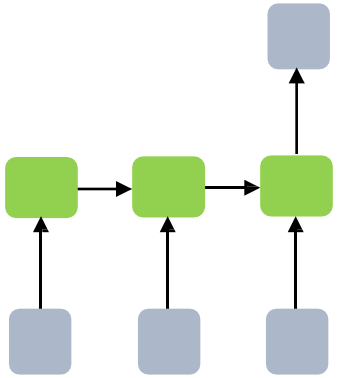

다 대 일(many-to-one)

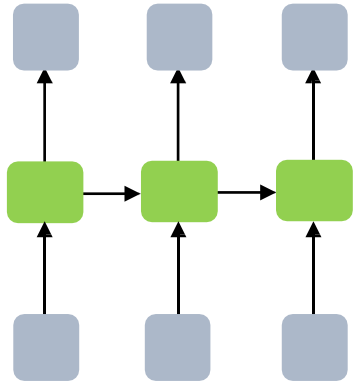

다 대 다(many-to-many)

그림 출처 : https://wikidocs.net/book/2155

RNN 구조

다 대 일(many-to-one) 구조의 RNN

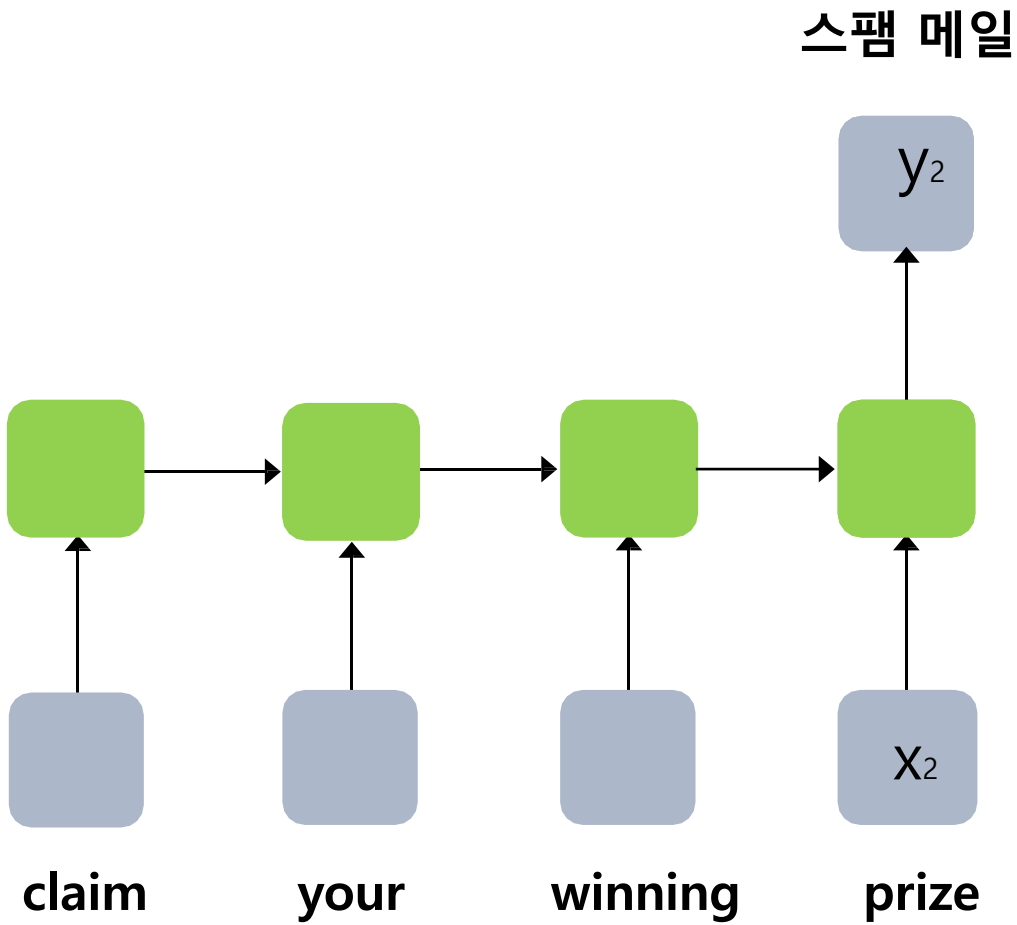

스팸 메일 분류

그림 출처 : https://wikidocs.net/book/2155

RNN 구조

다 대 다(many-to-many) 구조의 RNN

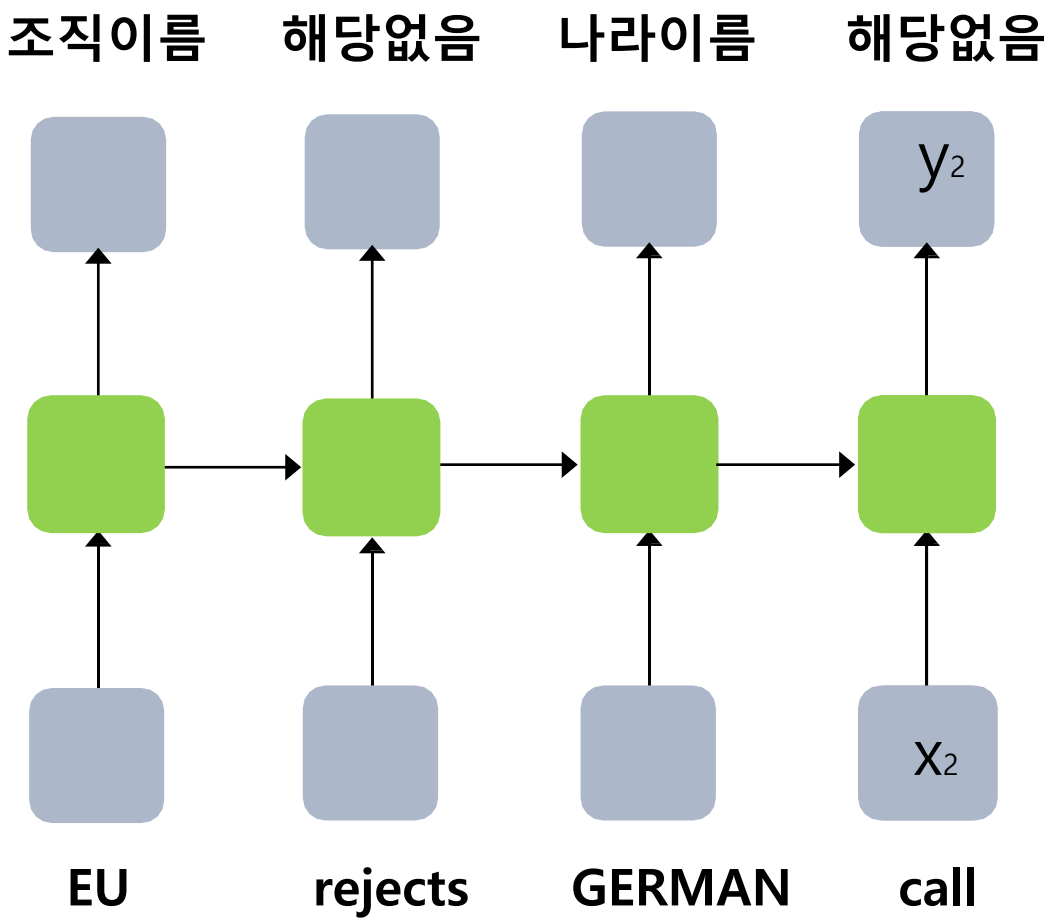

개체명 인식

그림 출처 : https://wikidocs.net/book/2155

RNN 학습구조

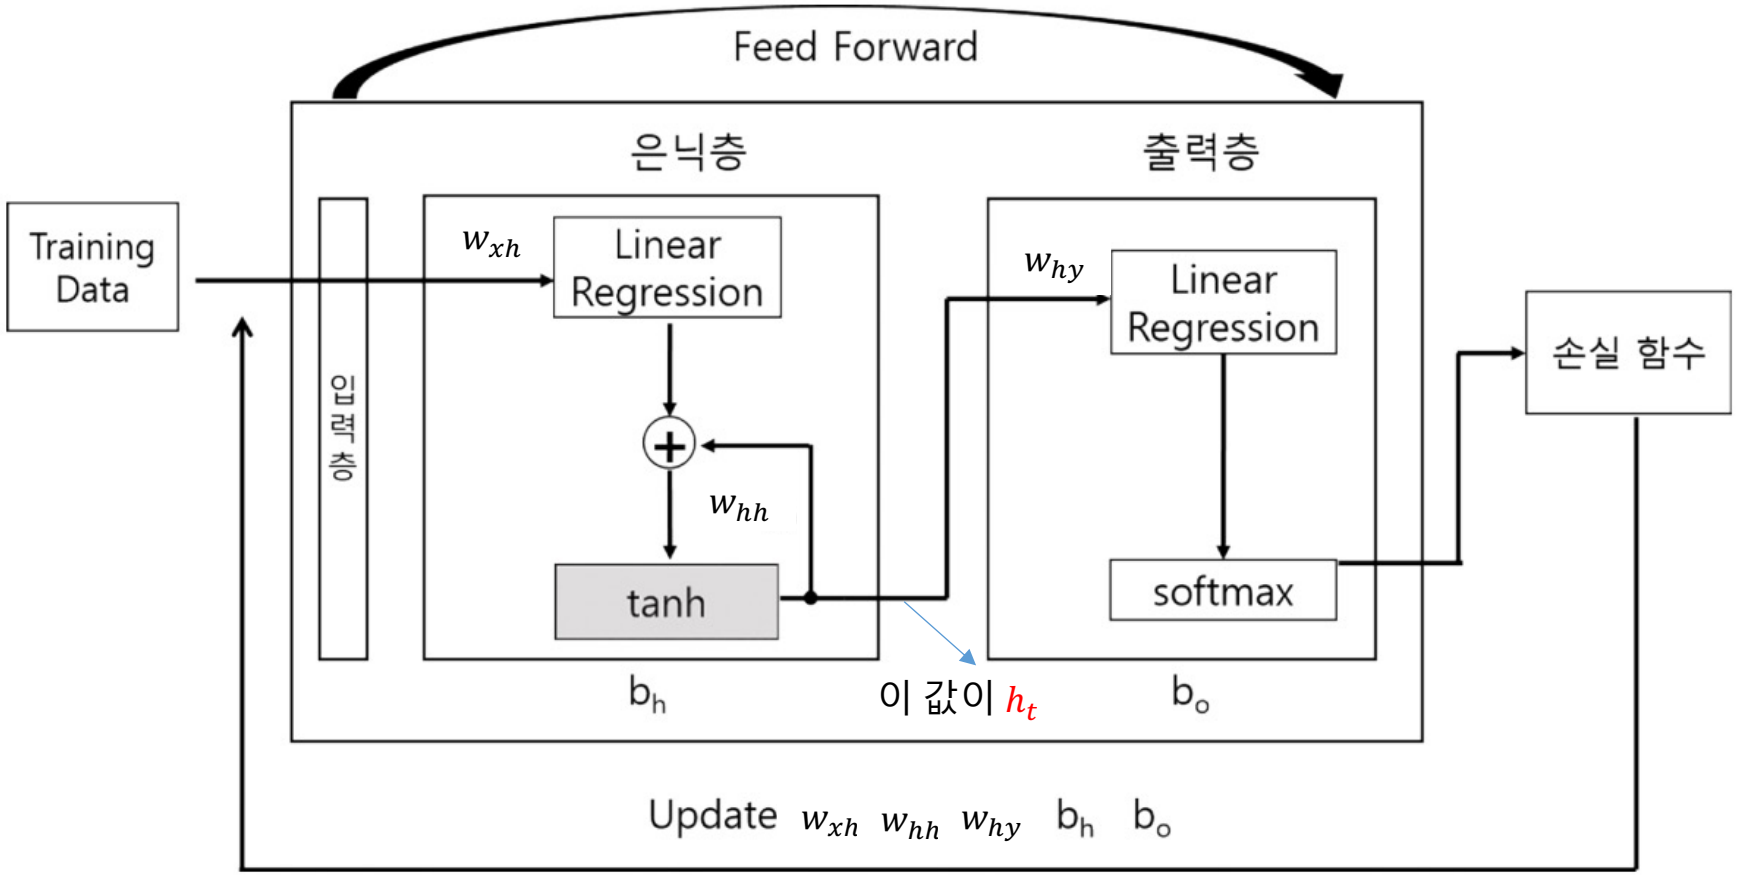

$$h_t = \tanh(X_t \cdot W_{xh} + h_{t-1} \cdot W_{hh} + b)$$

$$y_t = W_{hy} \cdot h_t$$

그림 출처 : 머신러닝을 위한 파이썬 한조각

RNN 학습구조

RNN을 벡터와 행렬 연산으로 표현하면?

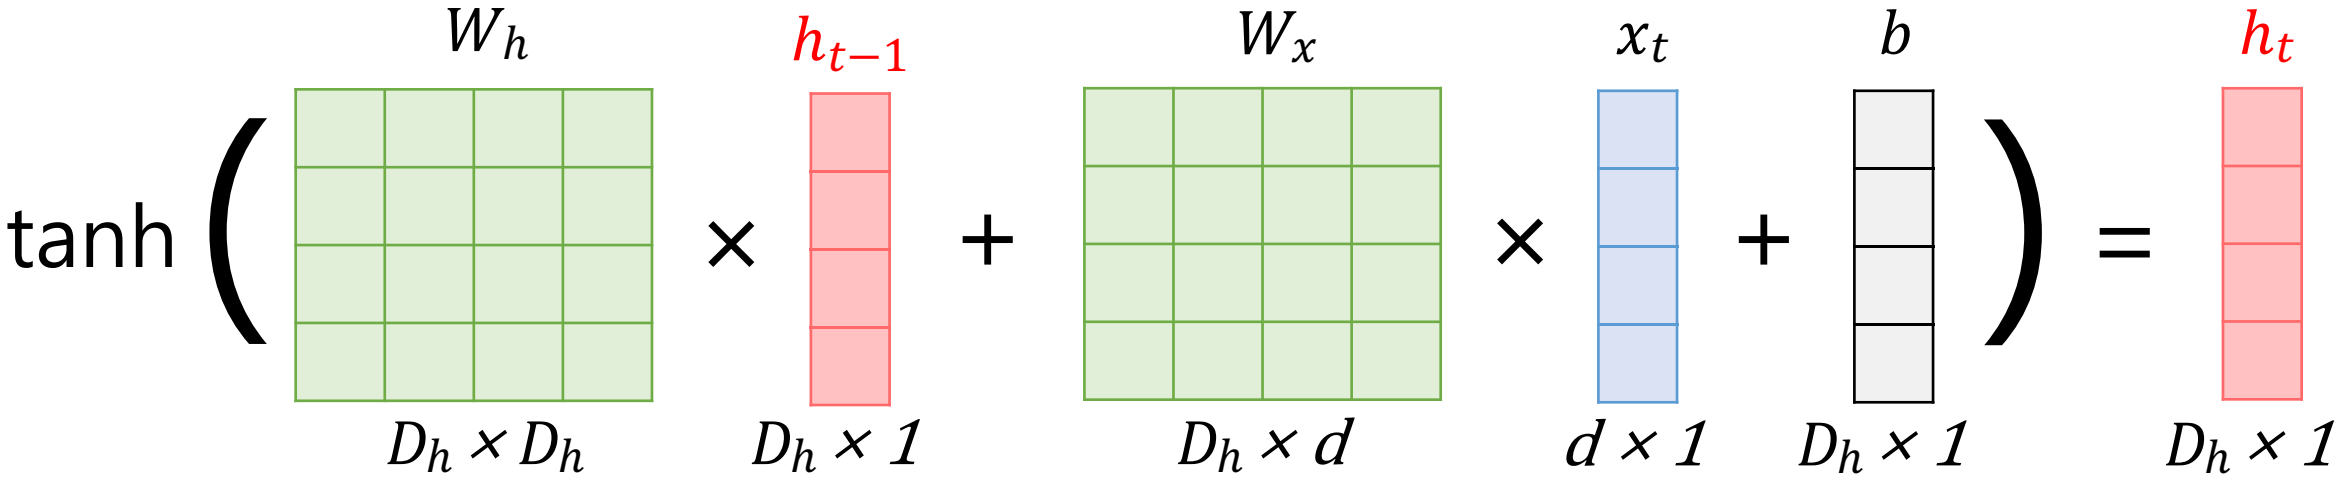

d: t time-step의 단어의 차원
D_h : hidden size의 크기

그림 출처 : https://wikidocs.net/book/2155

CONTENTS

시계열 데이터에 대한 RNN의 활용

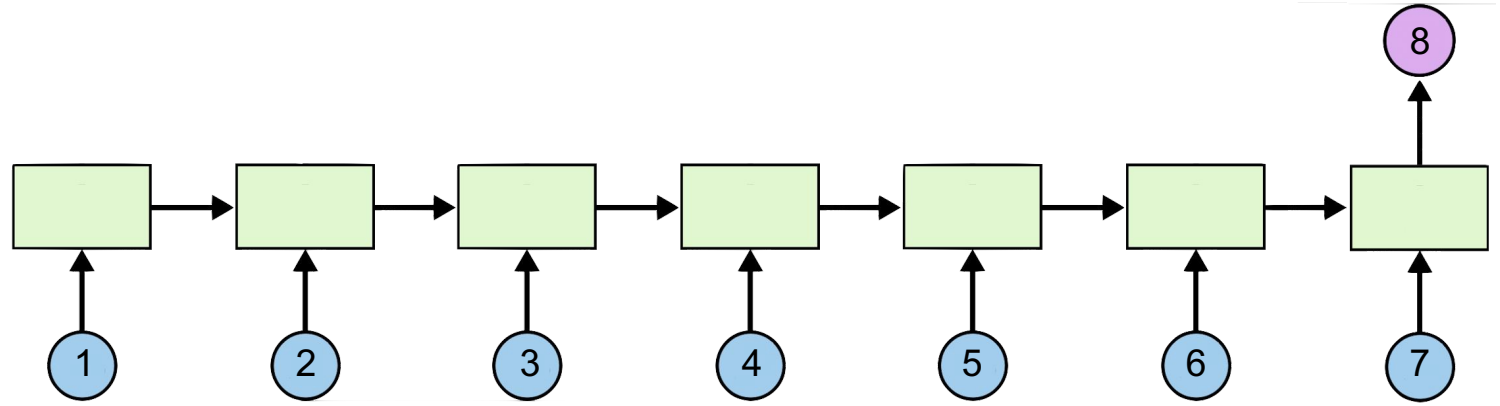

Day	1	2	3	4	5	6	7
Open	828.659973	823.02002	823.02002	819.929993	819	816	811.700012
High	833.450012	828.070007	824.400024	823	823	820.958984	815.25
Low	828.349976	821.655029	818.97998	818.469971	816	815.48999	809.780029
Volume	1247700	1597800	1281700	1304000	1053600	1198100	1129100
Close	831.659973	828.070007	824.159973	818.97998	820.450012	819.23999	813.669983

그림 출처 : 모두의 딥러닝 시즌2

RNN 활용 (시계열 데이터의 활용)

RNN 데이터의 준비

```
16  def build_dataset(time_series, seq_length):
17      dataX = []
18      dataY = []
19      for i in range(0, len(time_series) - seq_length):
20          _x = time_series[i:i + seq_length, :]
21          _y = time_series[i + seq_length, [-1]]
22          print(_x, "->", _y)
23          dataX.append(_x)
24          dataY.append(_y)
25      return np.array(dataX), np.array(dataY)
26
27
```

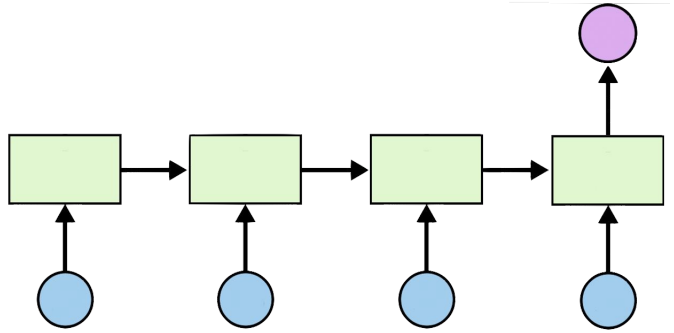

Day	1	2	3	4	5	6	7
Open	828.659973	823.02002	823.02002	819.929993	819	816	811.700012
High	833.450012	828.070007	824.400024	823	823	820.958984	815.25
Low	828.349976	821.655029	818.97998	818.469971	816	815.48999	809.780029
Volume	1247700	1597800	1281700	1304000	1053600	1198100	1129100
Close	831.659973	828.070007	824.159973	818.97998	820.450012	819.23999	813.669983

그림 출처 : 모두의 딥러닝 시즌2

RNN 활용 (시계열 데이터의 활용)

RNN 데이터의 준비

```
55  class Net(torch.nn.Module):
56      def __init__(self, input_dim, hidden_dim, output_dim, layers):
57          super(Net, self).__init__()
58          self.rnn = torch.nn.LSTM(input_dim, hidden_dim, num_layers=layers, batch_first=True)
59          self.fc = torch.nn.Linear(hidden_dim, output_dim, bias=True)
60
61      def forward(self, x):
62          x, _status = self.rnn(x)
63          x = self.fc(x[:, -1]) re
64          turn x
65
66
67  net = Net(data_dim, hidden_dim, output_dim, 1)
68
69  # loss & optimizer setting
70  criterion = torch.nn.MSELoss()
71  optimizer = optim.Adam(net.parameters(), lr=learning_rate)
72
```

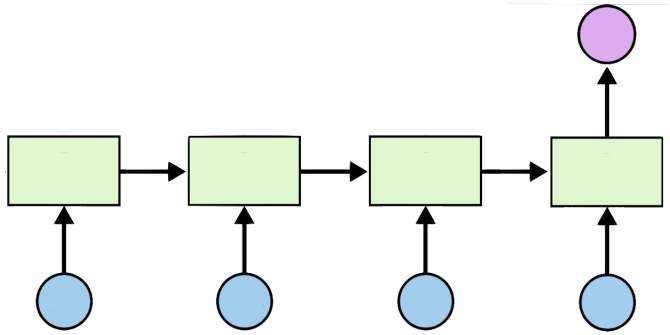

그림 출처 : 모두의 딥러닝 시즌2

RNN 활용 (시계열 데이터의 활용)

RNN모델의 학습 및 평가

```
73  for i in range(iterations):
74
75      optimizer.zero_grad()
76      outputs = net(trainX_tensor)
77      loss = criterion(outputs, trainY_tensor)
78      loss.backward()
79      optimizer.step()
80      print(i, loss.item())
81
82  plt.plot(testY)
83  plt.plot(net(testX_tensor).data.numpy())
84  plt.legend(['original', 'prediction'])
85  plt.show()
86
```

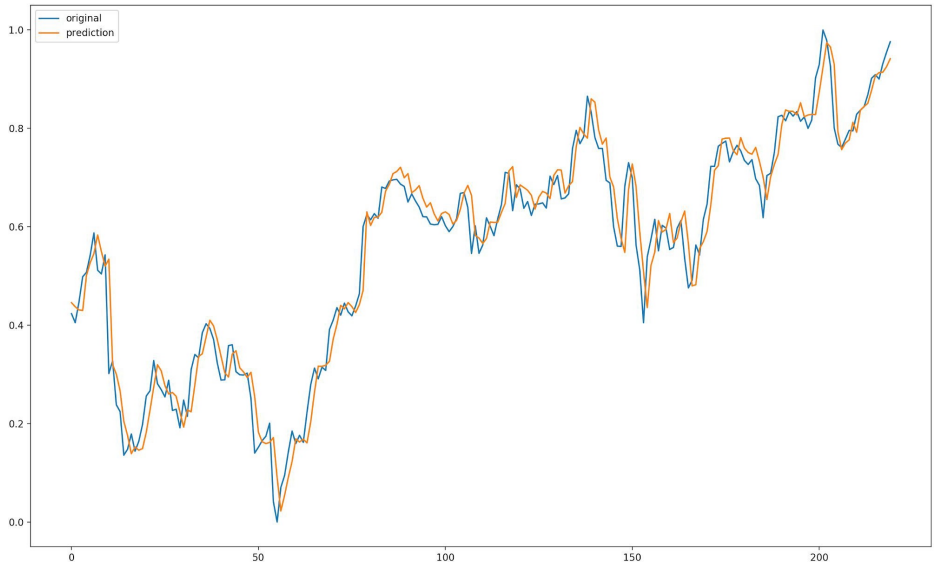

그림 출처 : 모두의 딥러닝 시즌2


감사합니다.